

# Doğrusal Regresyon ve Kuzenleri

by Sefa Isci

# Doğrusal Regresyon ve Kuzenleri

---

- Basit Doğrusal Regresyon
- Çoklu Doğrusal Regresyon
- Temel Bileşen Regresyonu
- Kısmi En Küçük Kareler Regresyonu
- Ridge Regresyon
- Lasso Regresyon
- Elastic Net Regresyonu
- Her Model İçin:
  - Model
  - Tahmin
  - Model Optimizasyonu

# Basit Doğrusal Regresyon

---

**Temel amaç, bağımlı ve bağımsız değişken arasındaki ilişkiyi ifade eden doğrusal fonksiyonu bulmaktır.**

# Basit Doğrusal Regresyon



Anakitle teorik gösterim:  $Y = \beta_0 + \beta_1 X + \varepsilon$

Örneklem gerçek değerler:  $y_i = b_0 + b_1 x_i + e_i$

Tahmin modeli:  $\hat{y}_i = b_0 + b_1 x_i$

$\beta_0$  = Doğrunun y eksenini kestiği nokta

$\beta_1$  = Doğrunun eğimi

$\varepsilon$  = Hata terimi

# Basit Doğrusal Regresyon

Örnekleme teorik gösterim:

$$y_i = b_0 + b_1 x_i + e_i$$

Tahmin modeli:

$$\hat{y}_i = b_0 + b_1 x_i$$

Hatalar/artıklar:

$$e_i = y_i - \hat{y}_i$$




$$e_i = y_i - b_0 - b_1 x_i$$


$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$SSE = \sum_{i=1}^n (y_i - (b_0 + b_1 x_i))^2$$

# Basit Doğrusal Regresyon

$$SSE = \sum_{i=1}^n (y_i - (b_0 + b_1 x_i))^2$$


$$b_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$


$$b_0 = \bar{y} - b_1 \bar{x}$$


Bağımsız değişkenin ortalaması



Bağımlı değişkenin ortalaması

# Basit Doğrusal Regresyon Geometrik Gösterim




$$y_i = b_0 + b_1 x_i + e_i$$

Gerçek y değerleri

$$\hat{y}_i = b_0 + b_1 x_i$$

Tahmin fonksiyonu ve  
tahmin edilen değerler

# Basit Doğrusal Regresyon Geometrik Gösterim



$$y_i = b_0 + b_1 x_i + e_i$$


Gerçek y değerleri

$$\hat{y}_i = b_0 + b_1 x_i$$

Tahmin fonksiyonu ve  
tahmin edilen değerler



# Basit Doğrusal Regresyon Geometrik Gösterim



$$\hat{y}_i = b_0 + b_1 x_i$$



# Çoklu Doğrusal Regresyon

---

**Temel amaç, bağımlı ve bağımsız değişkenler arasındaki ilişkiyi ifade eden doğrusal fonksiyonu bulmaktır.**

# Çoklu Doğrusal Regresyon

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_j X_{ij} + \cdots + \beta_p X_{ip} + \varepsilon_i$$

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\hat{\beta} = (X^T \cdot X)^{-1} X^T \cdot Y$$

# Çoklu Doğrusal Regresyon

```
Call:
lm(formula = Sales ~ TV + Radio, data = caseStudyData)

Residuals:
    Min       1Q   Median       3Q      Max
-8.7977 -0.8752  0.2422  1.1708  2.8328

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   2.92110    0.29449   9.919  <2e-16 ***
TV             0.04575    0.00139  32.909  <2e-16 ***
Radio          0.18799    0.00804  23.382  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.681 on 197 degrees of freedom
Multiple R-squared:  0.8972,    Adjusted R-squared:  0.8962
F-statistic: 859.6 on 2 and 197 DF,  p-value: < 2.2e-16
```

# Çoklu Doğrusal Regresyon


## Doğrusal Regresyonun Varsayımları

- Hatalar normal dağılır.
- Hatalar birbirinden bağımsızdır ve aralarında otokorelasyon yoktur.
- Her bir gözlem için hata terimleri varyansları sabittir.
- Değişkenler ile hata terimi arasında ilişki yoktur.
- Bağımsız değişkenler arasında çoklu doğrusal ilişki problemi yoktur.



# Çoklu Doğrusal Regresyon

## Regresyon Modellerinin Avantaj ve Dezavantajları

- ✓ İyi anlaşılırsa diğer tüm ML ve DL konuları çok rahat kavranır. 
- ✓ Doğrusallık nedensellik yorumları yapılabilmesini sağlar, bu durum aksiyoner ve stratejik modelleme imkanı verir.
- ✓ Değişkenlerin etki düzeyleri ve anlamlılıkları değerlendirilebilir.
- ✓ Bağımlı değişkendeki değişkenliğin açıklanma başarısı ölçülebilir.
- ✓ Model anlamlılığı değerlendirilebilir.
- ❖ Varsayımları vardır.
- ❖ Aykırı gözlemlere duyarlıdır.

# PCR – Temel Bileşen Regresyonu


---

**Değişkenlere boyut indirgeme uygulandıktan sonra çıkan bileşenlere regresyon modeli kurulması fikrine dayanır.**


(Massy 1965)

# PCR - Temel Bileşen Regresyonu

Multiple linear regression



Principal component regression





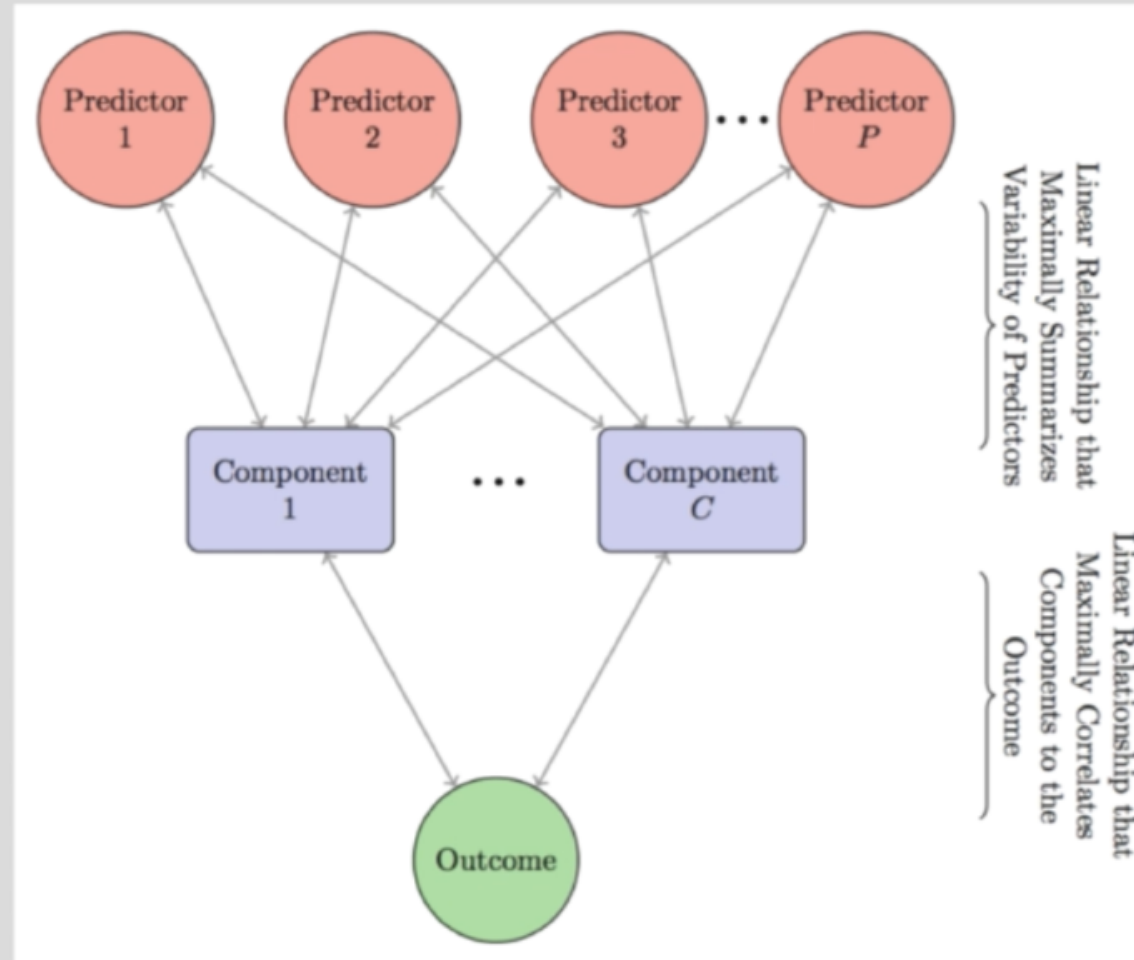
# PLS - Kısmi En Küçük Kareler Regresyonu

---


**Değişkenlerin daha az sayıda ve aralarında çoklu doğ. bağlantı problemi olmayan bileşenlere indirgenip regresyon modeli kurulması fikrine dayanır.**

Herman Wold (1966, 1982)


# PLS - Kısmi En Küçük Kareler Regresyonu



# PLS - Kısmi En Küçük Kareler Regresyonu

- Çok boyutluluk laneti  $p > n$
- Çoklu doğrusal bağlantı problemi
- PLS de PCR gibi bağımsız değişkenlerin doğrusal kombinasyonlarını bulur. Bu doğrusal kombinasyonlar bileşen ya da latent değişken olarak adlandırılır. 
- PLS NIPALS'in özel bir halidir, iteratif olarak bağımlı değişken ile yüksek korelasyona sahip değişkenler arasındaki gizil (latent) ilişkiyi bulmaya çalışır.

# PCR VS PLS

- PCR'da doğrusal kombinasyonlar yani bileşenler **bağımsız değişken uzağındaki değişkenliği** maksimum şekilde özetleyecek şekilde oluşturulur.
- Bu durum bağımlı değişkeni açıklama yeteneği olmamasına sebep olmakta.
- PLS'te ise **bileşenler bağımlı değişken ile olan kovaryansı** maksimum şekilde özetleyecek şekilde oluşturulur.
- Değişkenler atılmak istenmiyorsa ve açıklanabilirlik aranıyorsa: PLS
- PLS, gözetimli boyut indirgeme prosedürü, PCR gözetimsiz boyut indirgeme prosedürü olarak görülebilir.
- İki yönteminde  bir tunning parametresi vardır o da bileşen sayısıdır.
- Optimum bileşen sayısını belirlemek için CV yöntemi kullanılır.

# Ridge Regresyon

---

**Amaç hata kareler toplamını minimize eden katsayıları bu katsayılara bir ceza uygulayarak bulmaktır**

Hoerl & Kennard 1970

# Ridge Regresyon

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

# Ridge Regresyon

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$SSE_{L_2} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^P \beta_j^2$$

Ayar Parametresi Lambda

Ceza Terimi

# Ridge Regresyon

- Aşırı öğrenmeye karşı dirençli.
- Yanlıdır fakat varyansı düşüktür. (Bazen yanlı modelleri daha çok tercih ederiz.)
- Çok fazla parametre olduğunda EKK'ya göre daha iyidir.
- Çok boyutluluk lanetine karşı çözüm sunar.
- Çoklu doğrusal bağlantı problemi olduğunda etkilidir.
- Tüm değişkenler ile model kurar. İlgisiz değişkenleri modelden çıkarmaz, katsayılarını sıfıra yaklaştırır.
- $\lambda$  kritik roldedir. İki terimin (formüldeki) göreceli etkilerini kontrol etmeyi sağlar.
- $\lambda$  için iyi bir değer bulunması önemlidir. Bunun için CV yöntemi kullanılır.



# Lasso Regresyon

---

**Amaç hata kareler toplamını minimize eden katsayıları bu katsayılara bir ceza uygulayarak bulmaktır**

Tibshirani 1996

# Lasso Regresyon

$$SSE_{L_1} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \underbrace{\lambda}_{\text{Ayar Parametresi Lambda}} \underbrace{\sum_{j=1}^P |\beta_j|}_{\text{Ceza Terimi}}$$



# Lasso Regresyon

- Ridge regresyonun ilgili-ilgisiz tüm değişkenleri modelde bırakma dezavantajını gidermek için önerilmiştir.
- Lasso'da katsayıları sıfıra yaklaştırır.
- Fakat L1 normu  $\lambda$  yeteri kadar büyük olduğunda bazı katsayıları sıfır yapar. Böylece değişken seçimi yapmış olur.
- $\lambda$ 'nın doğru seçilmesi çok önemlidir, burada da CV kullanılır.
- Ridge ve Lasso yöntemleri birbirinden üstün değildir.



## $\lambda$ Ayar Parametresinin Belirlenmesi

# Lasso Regresyon

- $\lambda$ 'nın sıfır olduğu yer EKK'dır. HKT'yi minimum yapan  $\lambda$ 'yı arıyoruz
- $\lambda$  için belirli değerleri içeren bir küme seçilir ve her birisi için cross validation test hatası hesaplanır.
- En küçük cross validation'ı veren  $\lambda$  ayar parametresi olarak seçilir.
- Son olarak seçilen bu  $\lambda$  ile model yeniden tüm gözlemlere fit edilir.

# ElasticNet Regresyonu

---

**Amaç hata kareler toplamını minimize eden katsayıları bu katsayılara bir ceza uygulayarak bulmaktır. ElasticNet L1 ve L2 yaklaşımlarını birleştirir.**



Zou & Hastie 2005

## ElasticNet Regresyonu

$$SSE_{Enet} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda_1 \sum_{j=1}^P \beta_j^2 + \lambda_2 \sum_{j=1}^P |\beta_j|$$

# ElasticNet Regresyonu

L2 ve L1 Ayar Parametleri

$$SSE_{Enet} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \boxed{\lambda_1} \sum_{j=1}^P \beta_j^2 + \boxed{\lambda_2} \sum_{j=1}^P |\beta_j|$$

Ceza Terimleri